

CETEC UBATIC 2026-27

Grupo 2: Qdrant + CLIP/CONCH + LangGraph/ADK

Informe Técnico - Sprint 2

Integración de CONCH, Named Vectors y Ampliación del corpus

Mateo Gonzalez Pautaso - Alen Calandria

Mayo 2026

1. Contexto y Objetivo del Sprint 2

El Sprint 1 dejó dos resultados validados que definieron el punto de partida del Sprint 2: el chunking de 500 caracteres alcanzó $\text{Recall}@3 = 0.40$ sobre un corpus de un solo PDF (arch2.pdf, 35 páginas), y CONCH ViT-B/16 logró $\text{Recall}@1 = 1.000$ en retrieval imagen→imagen, mientras que CLIP genérico obtuvo $\text{Recall}@1 = 0.000$. Ambos resultados se obtuvieron en un notebook de evaluación aislado, sin que CONCH estuviera integrado en el sistema principal.

Los objetivos del Sprint 2 fueron:

- Tarea 1: Integrar CONCH en el sistema principal CETEC_g2 como encoder visual, reemplazando CLIP en la modalidad imagen. Mantener CLIP-text para la modalidad textual durante esta migración.
- Tarea 2: Implementar chunking multimodal por página con pdfplumber, donde cada unidad atómica indexada contenga la imagen renderizada de la página y el texto enriquecido con metadatos estructurados de las tablas (laminilla, tejido, variedad, estructura señalada).
- Tarea 3: Iniciar la extracción de ontología histológica (Órgano → Tejido → Célula) a partir de las tablas del manual, como base para el filtrado por payload en sprints posteriores.

Adicionalmente, se amplió el corpus de 1 a 3 PDFs (arch2, arch3, arch4) para evaluar la robustez del sistema con material histológico nuevo: vasos sanguíneos (arch3, 8 páginas) y tejido testicular con espermatogénesis (arch4, 15 páginas). El golden set se expandió de 20 a 30 preguntas correspondientemente.

2. Arquitectura del Sistema RAG Multimodal v4.2

2.1 Visión General

La arquitectura del Sprint 2 mantiene las cuatro capas del Sprint 1 (ingesta, indexación, retrieval, generación) pero introduce un cambio estructural en la indexación: los embeddings de texto e imagen ahora son dimensionalmente distintos y se almacenan en named vectors separados dentro del mismo punto de Qdrant. Esto permite búsquedas desacopladas por modalidad sin perder la unidad lógica del punto multimodal.

La migración v3.2 → v4.2 implicó tres cambios principales:

- Reemplazo del encoder visual: CLIP ViT-B/32 (512d) → CONCH ViT-B/16 (768d).
- Nueva colección histologia_v4_multimodal con esquema de named vectors.
- Refactor de `_embed_imagen()` y `_search_qdrant()` para operar con vectores por modalidad.

2.2 Named Vectors en Qdrant

Las dimensiones de los encoders ya no coinciden (CLIP-text genera 512d, CONCH genera 768d), lo que hace imposible mantener un esquema de vector único. La solución adoptada fue usar named vectors, una característica nativa de Qdrant que permite que cada punto tenga múltiples vectores con dimensiones independientes.

Configuración de la colección:

```
vectors_config = {  
    'text': VectorParams(size=512, distance=Distance.COSINE),  
    'image': VectorParams(size=768, distance=Distance.COSINE),  
}
```

Las búsquedas se ejecutan con el parámetro `using='text'` o `using='image'` según la modalidad de la query:

Búsqueda por texto

```
qdrant.query_points(collection, query=emb_clip, using='text', limit=k)
```

Búsqueda por imagen

```
qdrant.query_points(collection, query=emb_conch, using='image', limit=k)
```

Esta separación permite que el sistema responda a queries puramente textuales sin contaminación del espacio visual, y viceversa. Los puntos de texto y los puntos de imagen se filtran automáticamente por modalidad sin necesidad de payload filtering manual.

2.3 Decisión: Crear Colección Nueva en vez de Migrar la Existente

Se decidió crear una colección nueva (`histologia_v4_multimodal`) en lugar de migrar in-place la colección del Sprint 1 (`histologia_multimodal`). Razones:

- La colección vieja tiene esquema de vector único (512d, CLIP). Migrarla requería borrarla y reindexar, lo que eliminaría la posibilidad de rollback.
- Mantener ambas colecciones permite comparar empíricamente sistema viejo vs. nuevo en futuras sesiones.
- El costo de Qdrant Cloud (tier gratuito) lo permite sin riesgo de exceder cuota.

La colección antigua se borrará una vez que el sistema nuevo pase evaluación RAGAS completa en Sprint.

3. Tarea 1: Integración de CONCH en el Sistema Principal

Esta fue la tarea principal del sprint y se completó al 100%. El Sprint 1 había validado CONCH en un notebook de evaluación aislado; el Sprint 2 lo trajo al sistema productivo.

3.1 Refactor de la Clase Principal

Tres métodos de `AsistenteHistologiaMultimodal` fueron reescritos:

`_init_conch()`: reemplazo de `_init_clip()` para inicializar el encoder visual. Carga el checkpoint `MahmoodLab/conch` desde HuggingFace usando `timm` con la arquitectura `vit_base_patch16_224`. Reporta 150 missing keys y 174 unexpected keys (esperado, CONCH tiene capas adicionales específicas para contrastive learning) pero produce embeddings funcionales de 768 dimensiones con norma = 1.0.

`_embed_imagen()` y `_embed_imagen_pil()`: ahora generan embeddings de 768d con CONCH en lugar de 512d con CLIP. La transformación de imagen se reemplazó por la pipeline estándar de ImageNet (Resize 224, CenterCrop, normalización mean/std).

`_search_qdrant()`: agregado el parámetro `using='text'` o `using='image'` según el tipo de embedding recibido. Resuelve el ruteo a cada espacio vectorial dentro de la colección.

3.2 Detalle Crítico de la Carga de CONCH

El repositorio MahmoodLab/conch en HuggingFace contiene solo el checkpoint `pytorch_model.bin` sin `config.json` compatible con Transformers. La carga correcta requiere:

```
import timm

conch_vit = timm.create_model(
    'vit_base_patch16_224',
    pretrained=False,
    num_classes=0 # devuelve features, no logits
)

# Extraer pesos visuales sin el prefijo 'visual.'
visual_sd = {
    k.replace('visual.', ''): v
    for k, v in checkpoint.items()
    if k.startswith('visual.')
}

visual_sd.pop('proj_contrast', None) # capa contrastive, no parte del ViT

missing, unexpected = conch_vit.load_state_dict(visual_sd, strict=False)
```

Detalle importante encontrado durante la integración: el `import import timm` debe estar dentro del método `_init_conch()` y no a nivel de módulo, debido al scope de clase en Colab cuando se define `AsistenteHistologiaMultimodal` en una celda separada de las dependencias.

3.3 Smoke Test de Validación

Después de cargar CONCH, el sistema ejecuta automáticamente un smoke test:

- Genera un embedding de imagen aleatoria de 224x224.
- Verifica que la dimensión sea 768.
- Verifica que la norma L2 sea 1.0 (embedding normalizado).

Output esperado del smoke test:

Checkpoint OK | keys totales: 326

Missing: 150 | Unexpected: 174

Smoke test OK | dim=768 | norma=1.0

CONCH en cuda

3.4 Verificación End-to-End

Una celda de test (10b en el notebook v4.2) ejecuta dos búsquedas para confirmar el ruteo correcto:

- Query textual sobre cartílago hialino → devuelve solo puntos con tipo='texto', similitud 0.87-0.89 (CLIP-text en su espacio nativo).
- Query visual con una página de arch2 → devuelve solo puntos con tipo='imagen', similitud 0.99-1.00 (CONCH en su espacio nativo).

La similitud de 1.00 en el primer resultado de la búsqueda visual corresponde al caso esperado donde la imagen consulta consigo misma (presente en la colección). El comportamiento separado por modalidad confirma que los named vectors operan correctamente.

4. Ampliación del Corpus y Golden Set

4.1 Composición del PDF Concatenado

El Sprint 1 trabajó con un único PDF (arch2.pdf, 35 páginas). Para Sprint 2 se concatenaron tres documentos en un único histologia_completo.pdf de 58 páginas:

PDF fuente	Páginas en concatenado	Contenido
arch2.pdf	1-35	Cartílago, hueso, músculo, tejido nervioso (Sprint 1)
arch3.pdf	36-43	Vasos sanguíneos: arteria muscular, esófago
arch4.pdf	44-58	Testículo, espermatogénesis

La decisión de concatenar fuera del notebook (en lugar de modificar la lógica de iteración sobre múltiples PDFs) responde a tres razones:

- Cambio mínimo en el código de evaluación, manteniendo comparabilidad con Sprint 1.
- Reproducibilidad: el mismo archivo de 58 páginas se usa en todas las corridas.
- Esta decisión es temporal. En Sprint 3, con el chunking multimodal etiquetando cada chunk con su fuente, será natural iterar sobre PDFs separados.

4.2 Golden Set Ampliado

Se construyó un golden set de 30 pares pregunta-respuesta, distribuidos:

- arch2: 20 preguntas (idéntico al Sprint 1, sin cambios).
- arch3: 4 preguntas (túnicas arteriales, endotelio, lámina elástica, comparación vasos).
- arch4: 6 preguntas (epitelio seminífero, espermatogonias, células de Sertoli, Leydig, peritubulares, espermátides).

Para arch4 se identificó una limitación importante durante la construcción del golden set: las páginas 46-58 contienen casi exclusivamente imágenes con captions de una sola línea (ej. "Imagen 12: Espermatogonia A clara"). La descripción textual de todas las células testiculares

está concentrada en las páginas 44 y 45. Por esta razón, todas las preguntas de arch4 tienen `paginas_esperadas = [44, 45]` como referencia textual, aunque las imágenes ilustrativas estén en páginas posteriores.

5. Resultados

5.1 Evaluación Texto: Recall@K sobre Corpus Ampliado

Se reindexaron las tres colecciones de evaluación (`histologia_eval_pagina`, `histologia_eval_500`, `histologia_eval_250`) con el PDF concatenado de 58 páginas y se ejecutó el mismo pipeline de Recall@K del Sprint 1, ahora sobre 30 preguntas.

Configuración	Recall@1	Recall@3	Recall@5
<code>histologia_eval_pagina</code>	0.167	0.300	0.333
<code>histologia_eval_500</code>	0.167	0.200	0.367
<code>histologia_eval_250</code>	0.133	0.233	0.267

Los valores absolutos son inferiores a los del Sprint 1 ($\text{Recall@3} = 0.40$ con chunks de 500 caracteres sobre arch2 solo). Esta regresión aparente no es un fallo del sistema, sino el efecto esperado de tres factores:

- El golden set creció de 20 a 30 preguntas, incluyendo material (arch3, arch4) donde el texto disponible es muy escaso.
- El espacio de búsqueda creció de 35 a 58 páginas. Más páginas compiten por los top-K slots con scores comparables.
- El chunking actual (texto plano de pdfplumber sin metadatos estructurados) no escala bien cuando el corpus mezcla dominios histológicos distintos.

Breakdown por PDF (configuración `histologia_eval_pagina`)

Para entender la fuente de las fallas, se descompuso el Recall por PDF:

Sección	Recall@1	Recall@3	Recall@5
arch2 (20 preguntas)	0.100	0.150	0.200
arch3 (4 preguntas)	0.000	0.250	0.250
arch4 (6 preguntas)	0.500	0.833	0.833

El breakdown revela un patrón contraintuitivo: arch4, que parecería el más difícil por tener mayoría de imágenes sin texto, obtuvo $\text{Recall@3} = 0.833$ con página completa. Esto es porque toda la descripción textual está concentrada en dos páginas (44, 45) y el sistema las recupera correctamente. En cambio, arch2 bajó porque las queries del Sprint 1 ahora compiten con un espacio de búsqueda casi el doble.

La conclusión técnica es que el chunking de texto plano no escala bien al ampliar el corpus. La Tarea 2 (chunking multimodal por página con metadatos estructurados) es la intervención correcta para resolver esto.

5.2 Evaluación Imagen→Imagen: CONCH Mantiene Recall@1 = 1.000

El resultado más importante del sprint es la confirmación de que CONCH mantiene su rendimiento perfecto al triplicar la variedad del corpus.

Modelo	Recall@1	Recall@3	Recall@5
CLIP ViT-B/32	0.000 (0/58)	0.034 (2/58)	0.069 (4/58)
CONCH ViT-B/16	1.000 (58/58)	1.000 (58/58)	1.000 (58/58)

Sprint 1 había validado CONCH = 1.000 sobre 35 páginas de arch2. Sprint 2 confirma que el comportamiento se mantiene sobre 58 páginas que ahora incluyen vasos sanguíneos y tejido testicular, dominios visuales que no aparecían en Sprint 1. Este resultado valida definitivamente la migración a CONCH.

CLIP, en cambio, falla en 56 de las 58 páginas. El diagnóstico automático del sistema clasificó las fallas: 0 con score < 0.22 (no es problema de threshold ni imagen pequeña) y 56 con score ≥ 0.22 pero página incorrecta (problema estructural del modelo). Patrón consistente con Sprint 1: las páginas 23 (sarcómera en blanco y negro) y 10 (osteona en escala de grises) aparecen repetidamente como falsos positivos para preguntas que esperaban otras páginas.

5.3 Métricas RAGAS: Bloqueante Identificado

La intención original del Sprint 2 era ejecutar la evaluación RAGAS completa sobre las tres configuraciones de chunking. La ejecución no pudo completarse por un breaking change en RAGAS posterior al Sprint 1.

Cadena de errores encontrados:

- Primer intento: las métricas como referencias (context_precision, context_recall, faithfulness) ya no son válidas. RAGAS pide ahora métricas instanciadas como objetos.
- Segundo intento (con clases): ContextPrecision() requiere el parámetro llm en el constructor, no en evaluate().
- Tercer intento (con llm=llm_evaluador): el módulo ragas.metrics.collections solo acepta InstructorLLM con modelos OpenAI. ChatGroq ya no es compatible.

Mensaje exacto del error final:

```
Collections metrics only support modern InstructorLLM.
```

```
Found: ChatGroq. Use: llm_factory('gpt-4o-mini', client=openai_client)
```

Opciones consideradas:

- Downgrade a ragas==0.1.21 (versión compatible con Groq). Descartado: parche temporal que quedaría desactualizado en el próximo sprint.

- Migrar el evaluador a OpenAI gpt-4o-mini. Descartado por ahora: agrega dependencia de pago y una clave nueva al sistema.
- Postponer RAGAS completo al Sprint 3.

Se eligió la tercera opción. La celda 9 del notebook de evaluación quedó documentada con el bloqueante como evidencia de que se intentó y la incompatibilidad es de RAGAS, no del sistema RAG. Esta decisión no afecta la validación del Sprint 2: Recall@K + breakdown por PDF + test imagen→imagen son suficientes para confirmar que CONCH funciona y que la próxima intervención necesaria es chunking multimodal.

6. Tareas Pendientes: Chunking Multimodal y Ontología

6.1 Tarea 2: Chunking Multimodal por Página

Tarea identificada como crítica durante la evaluación del Sprint 2 pero no completada en este sprint. El diagnóstico de Recall@K bajo en arch2 (regresión vs Sprint 1) confirma que el chunking de texto plano es insuficiente cuando el corpus mezcla dominios histológicos.

Diseño previsto:

- Cada página del PDF genera un único punto multimodal en Qdrant.
- El punto contiene el embedding de imagen (CONCH 768d) y el embedding de texto (CLIP-text 512d) en sus named vectors correspondientes.
- El payload incluye texto extraído por pdfplumber, metadatos parseados de las tablas (laminilla, tejido, variedad, estructura señalada), el path de la imagen renderizada y el número de página.

Esto cambia la unidad atómica de indexación: en lugar de chunks de texto plano de 500 caracteres, cada página se convierte en una unidad imagen+texto+metadatos. Las queries textuales pueden filtrar por payload (ej. 'solo páginas con tejido = Conectivo') antes de la similitud coseno, lo que debería elevar significativamente Recall@K.

6.2 Tarea 3: Extracción de Ontología

Tarea iniciada conceptualmente pero no implementada en este sprint. Las tablas del manual contienen la información jerárquica necesaria para construir una ontología Órgano → Tejido → Célula. Por ejemplo, la tabla de la página 1 produce:

Órgano: Tráquea

Tejido: Conectivo Especializado

Variedad: Cartilaginoso Hialino

Estructura señalada: Pericondrio (capa fibrosa, capa condrógena)

En Sprint 3 esta extracción se hará automáticamente como parte del pipeline de indexación, y el resultado se guardará tanto en el payload de Qdrant como en una estructura jerárquica auxiliar para futuras consultas filtradas.

7. Organización del Repositorio

Durante el Sprint 2 se creó el repositorio cetec-rag-histologia en GitHub con la siguiente estructura:

```
cetec-rag-histologia/
├── README.md, LICENSE, .gitignore, .env.example
├── notebooks/
│   ├── v3.2/ (CETEC_g2_v3_2.ipynb, Evaluacion_ChunkSize_v3_2.ipynb)
│   └── v4.2/ (CETEC_g2_v4_2.ipynb, Evaluacion_ChunkSize_v4_2.ipynb)
├── data/pdf/ (arch2, arch3, arch4, histologia_completo)
├── docs/
│   ├── sprint1/ (Informe_Tecnico_Sprint1.pdf)
│   └── sprint2/ (resultados_chunk_eval.json,
│               reporte_diagnostico_imagenes.json,
│               Informe_Tecnico_Sprint2.pdf)
└── src/ (placeholder para refactor futuro)
```

Se trabajó con dos ramas principales:

- Rama v3.2: contiene el notebook estabilizado del Sprint 1, mergeado a main al inicio del sprint.
- Rama v4.2: contiene los notebooks del Sprint 2 con CONCH integrado y named vectors. Pendiente de merge a main al cierre del sprint.

8. Conclusiones y Próximos Pasos

El Sprint 2 cumplió su objetivo principal: CONCH está integrado en el sistema productivo y validado sobre un corpus tres veces más amplio que el del Sprint 1. La migración a named vectors permite escalar el sistema a futuros encoders sin tocar el esquema de Qdrant.

Estado de las tareas del sprint:

Tarea	Estado	Notas
Integración CONCH	Completada	Recall@1 = 1.000 sobre 58 páginas
Named vectors	Completada	text:512d + image:768d operativos
Corpus ampliado	Completada	3 PDFs, 58 páginas, golden set de 30
Chunking multimodal	Pendiente Sprint	Identificada como crítica
Ontología $O \rightarrow T \rightarrow C$	Pendiente Sprint	Diseño conceptual listo
RAGAS completo	Pendiente Sprint	Bloqueante de librería

La regresión aparente en Recall@K de texto (de 0.40 a 0.30) no es un retroceso del sistema, sino un diagnóstico que confirma la necesidad de la Tarea 2. El sistema funciona correctamente; lo que falla es el paradigma de chunking de texto plano cuando el corpus crece en variedad.

Próximos pasos para Sprint 3:

- Implementar chunking multimodal por página con pdfplumber, generando unidades atómicas imagen+texto+metadatos.
- Reindexar la colección histologia_v4_multimodal con el nuevo chunking y re-evaluar Recall@K sobre el mismo golden set de 30 preguntas.
- Iniciar la extracción automática de ontología Órgano → Tejido → Célula a partir de las tablas del manual.
- Coordinar con los grupos G1 y G3 para alinear evaluadores RAGAS de cara al Sprint 3.